Predicció de la victòria al League of Legends mitjançant Xarxes Bayesianes

Modelització de Dades Complexes

Pol Ortiz (1706755) Pau Verdejo (1687736)

Maig 2026

Universitat Autònoma de Barcelona
Facultat de Ciències
Professora: Rosario Delgado de la Torre

Índex de la presentació

Context i Base de dades

Discretitzacions

Modelització

Validació i Tests Estadístics

Resultats i Conclusions

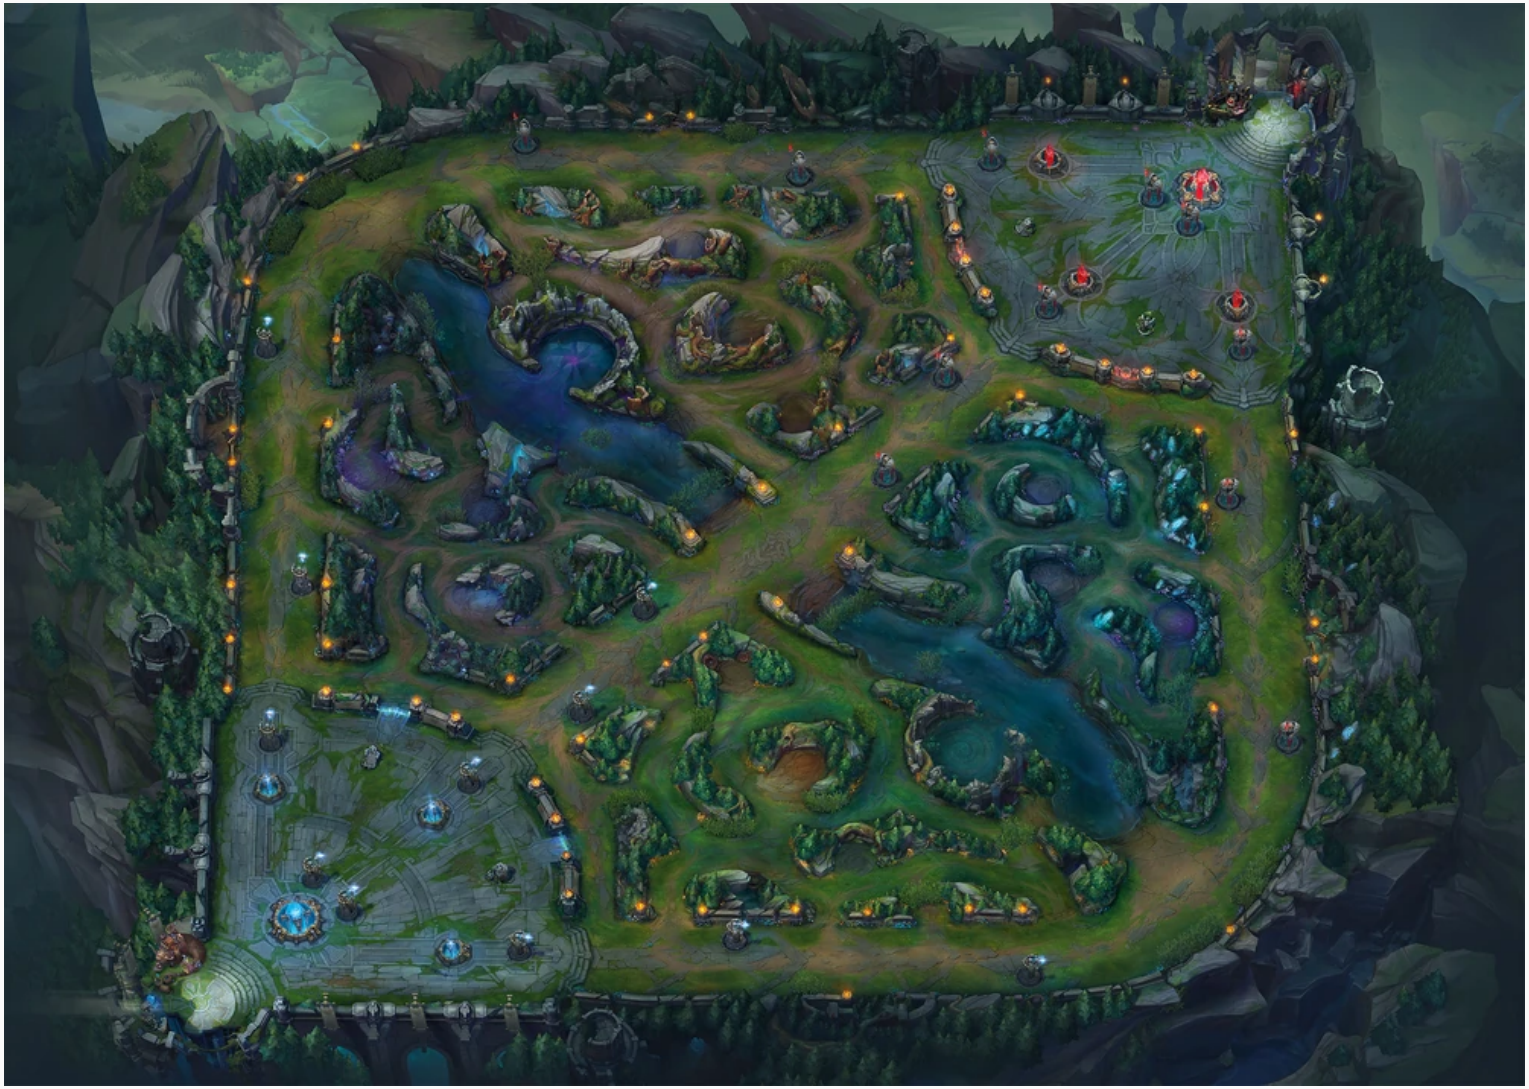
Estudi de Casos

Context i Base de dades

Context de l'estudi

- **Objectiu:** Predir la probabilitat de victòria de l'equip blau al minut 10.
- **El Joc:** League of Legends (LoL) — Gènere MOBA, 5 vs 5 jugadors.
- **Origen de les dades:** Kaggle (API oficial de Riot Games).
- **Dataset:** Partides de rang alt (Diamant/Màster).
- **Mida de la mostra:** $N = 9.879$ partides inicials.

Context de les variables



Hipòtesis de partida

Abans d'iniciar la modelització, hem definit els factors que considerem determinants per al desenllaç al minut 10:

1. **Economia i Nivell (Or i Experiència):** Predictors més sòlids. Un avantatge en or es tradueix en millors objectes i estadístiques base.
2. **Control d'objectius neutrals (Dracs):** El primer drac sol indicar quin equip controla el *tempo* de la partida.
3. **Pressió de mapa (Torres):** Destruir una torre abans del minut 10 és poc freqüent però té un impacte estratègic molt alt.
4. **Efecte "Snowball":** Esperem que el model ANB reflecteixi que les variables *no* són independents: més *kills* $\rightarrow$ més or $\rightarrow$ més torres.

Neteja de dades (Data Cleaning)

- Dataset sense valors nuls (*missing values*).
- **Outliers:** Filtratge per les variables de visió (`WardsPlaced`).
- **Mètode:** Eliminació de cues (quantils 0.025 i 0.975).
- **Resultat final:** $N = 9.131$ observacions netes.

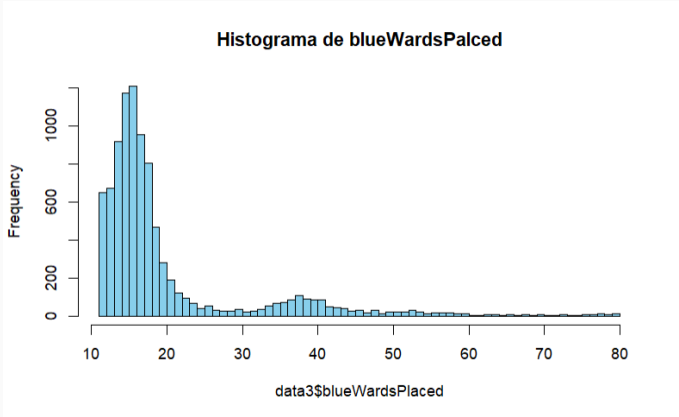


Figura 1: Distribució post-neteja

Discretitzacions

Estratègia de Discretització

Com que les Xarxes Bayesianes requereixen variables discretes, hem aplicat:

- **Variables Binàries:** `Dragons`, `Heralds`, `FirstBlood` (ja eren $\{0, 1\}$).
- **Mètode de Quantils ($n = 6$):** Aplicat a variables contínues com `Gold`, `Experience`, `Kills`. Garanteix categories equilibrades.
- **Torres:** Tres grups lògics: 0 torres, 1 torre, $\geq$2 torres.
- **Cas Especial (Wards):** Es va estudiar bimodalitat per valorar discretització manual vs. quantils.

Efecte de la discretització

La codificació per quantils garanteix categories equilibrades, reduint el risc de paràmetres mal estimats en les taules de probabilitat condicional (CPTs).

Modelització

Comparativa de les Arquitectures de Xarxa

Hem analitzat quatre models amb dos nivells de complexitat i dos conjunts de variables:

Naive Bayes (NB) — Estructura Fixa

Suposa que totes les variables predictores són **condicionalment independents** donada la classe (`blueWins`). Model de referència màximament restrictiu.

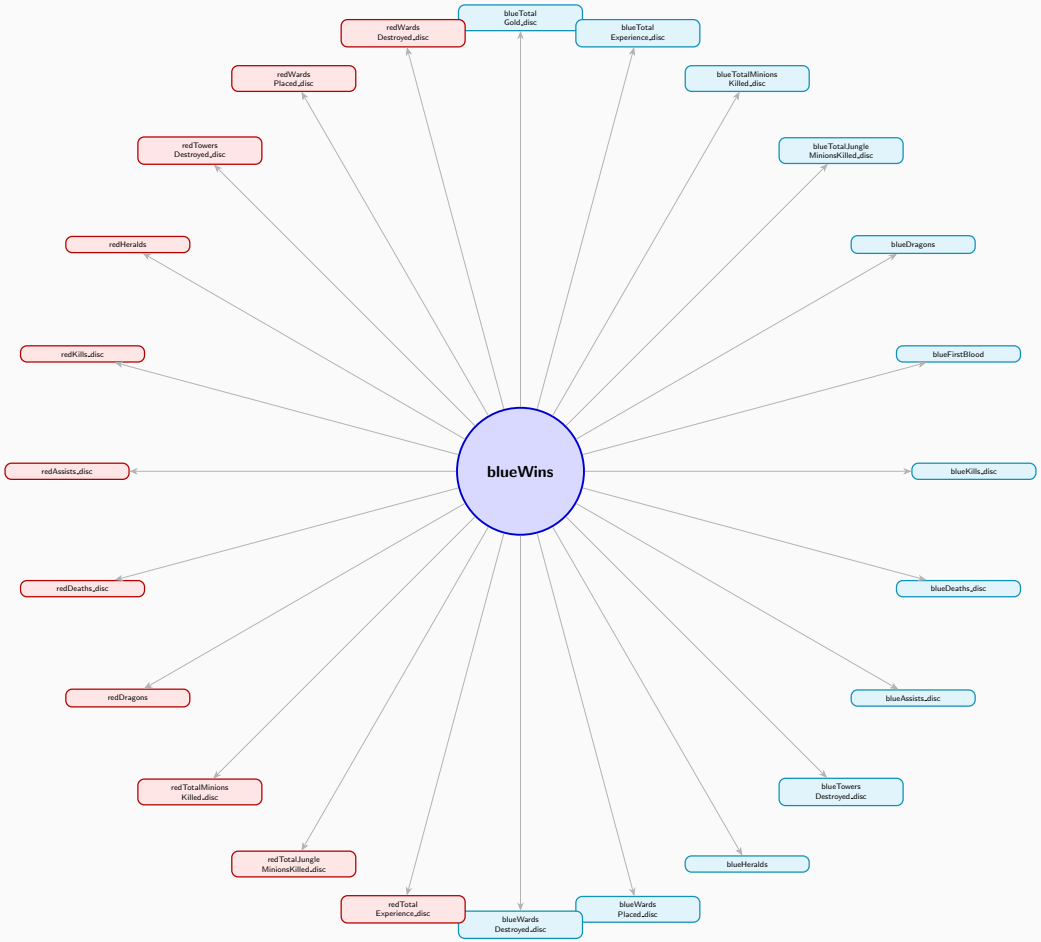
Augmented Naive Bayes (ANB) — Estructura Híbrida

Relaxa el supòsit d'independència afegint arcs entre predictors apresos per `hc` (Hill-Climbing), usant el NB com a *whitelist*. Captura sinergies (or $\leftrightarrow$ experiència, kills $\rightarrow$ or).

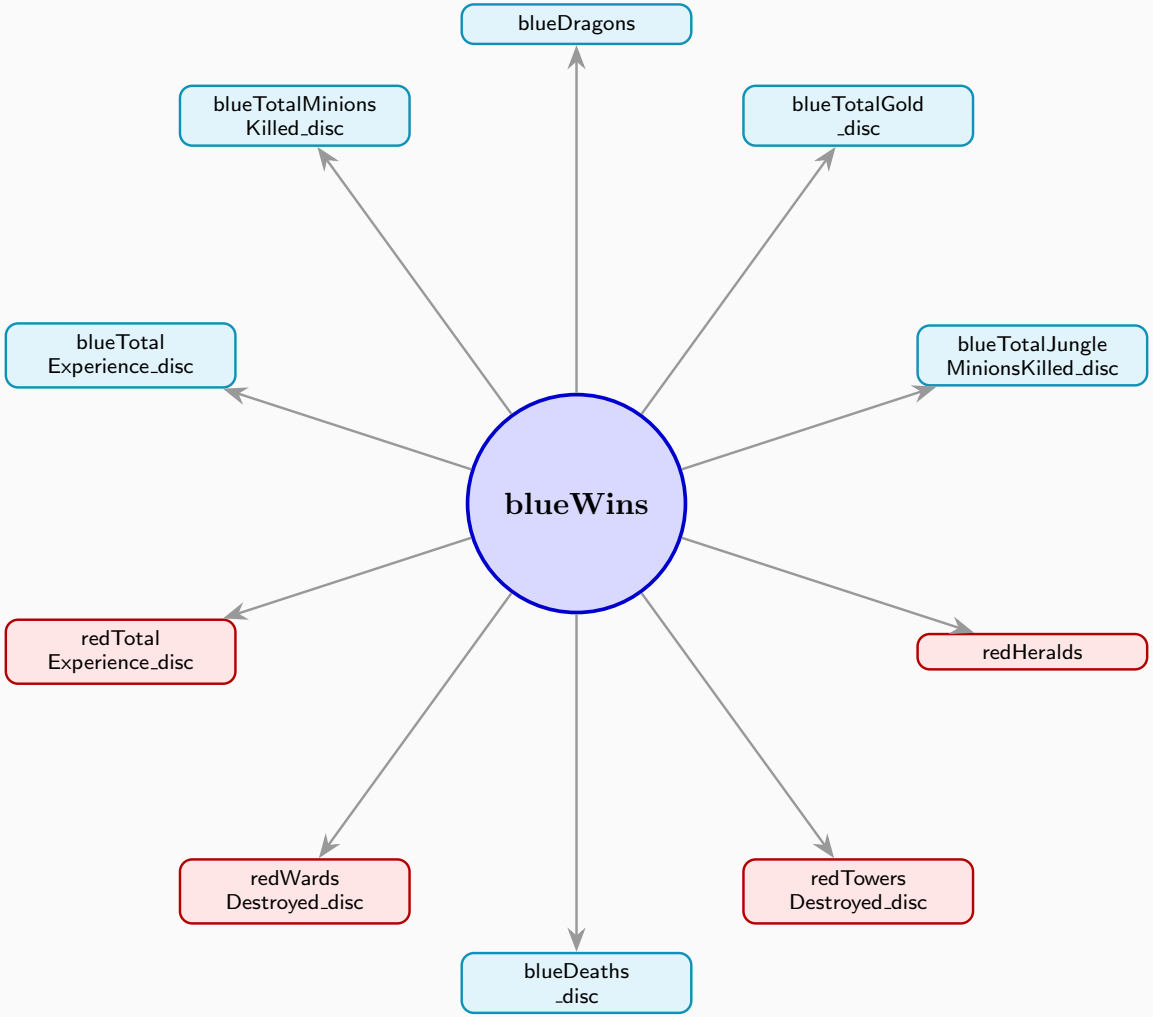
Selecció de variables: Full vs. Markov Blanket (MB)

El **Markov Blanket** s'obté estabilitzant els resultats de 15 folds de `hc`. El MB final conté **10 variables**

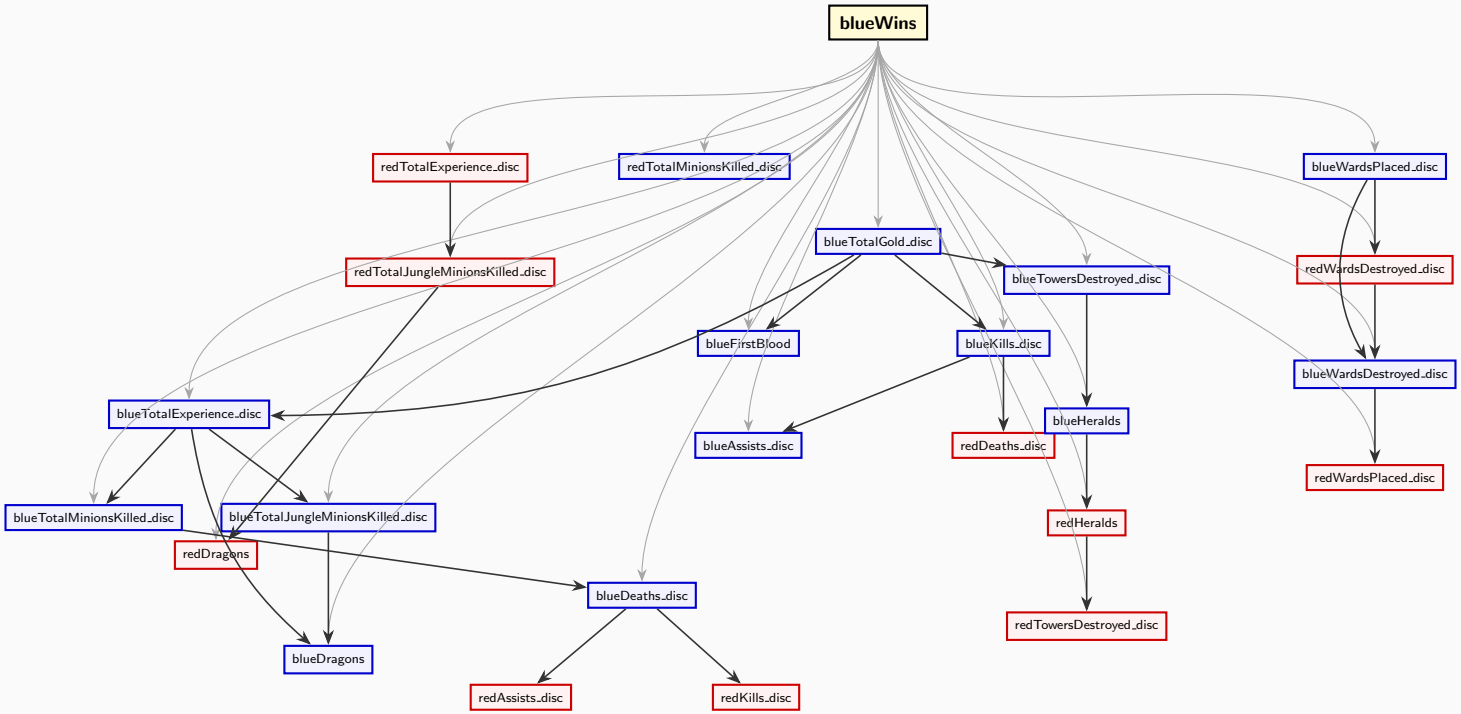
DAG: Naive Bayes (Full)



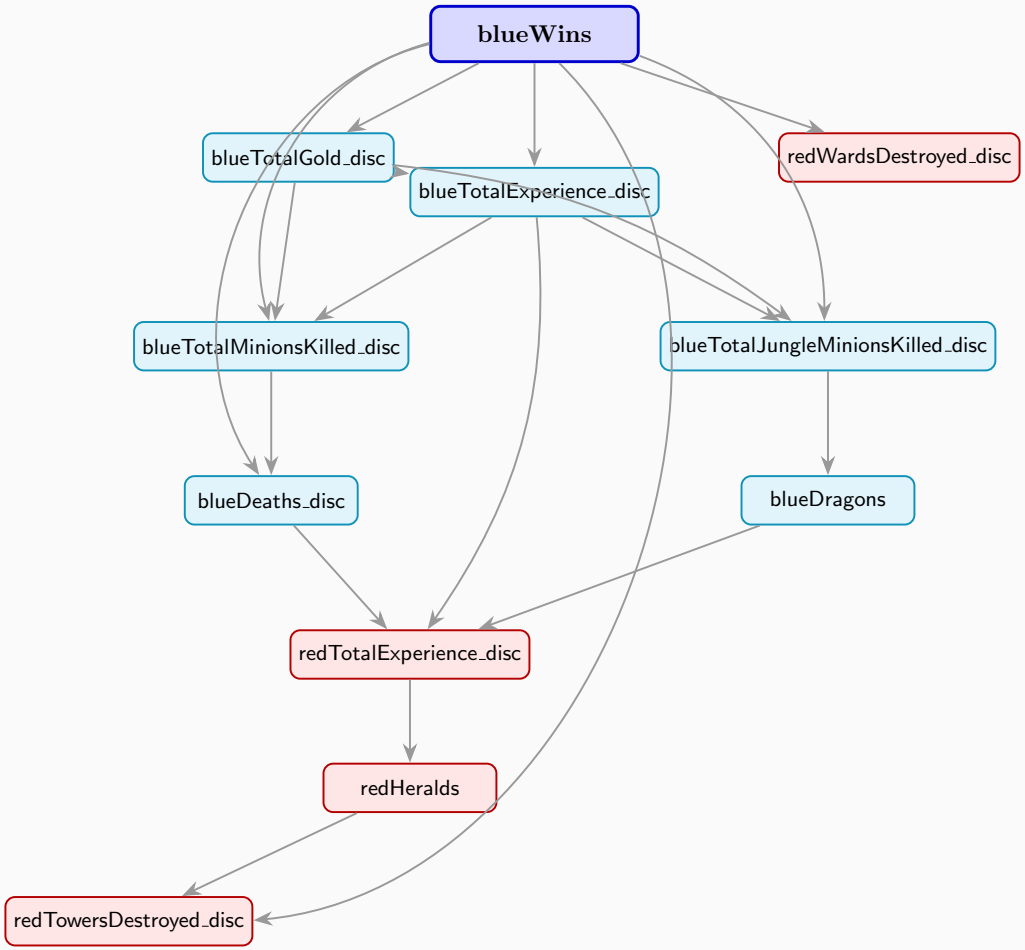
DAG: Naive Bayes amb Markov Blanket



DAG: Augmented Naive Bayes (Full)



DAG: Augmented Naive Bayes amb Markov Blanket



Validació i Tests Estadístics

Criteris de Selecció de Models

- **Mètriques de Classificació:**
  - **Accuracy:** Percentatge global d'encerts (10-fold CV).
  - **AUC-ROC:** Capacitat discriminant independent del llindar.
  - **F1-Score:** Equilibri precisió/exhaustivitat.
- **Qualitat Probabilística:**
  - **Brier Score:** Cal·libració de les probabilitats (com més baix, millor).
  - **Log-Likelihood:** Versemblança de les dades donats els paràmetres.
- **Complexitat i Parsimònia:**
  - **BIC:** Penalitza la complexitat (nombre d'arcs) per evitar *overfitting*.
  - **Nombre d'arcs:** Mesura d'interpretabilitat estructural.

Objectiu de la tria

Cercar el model que maximitzi la capacitat predictiva mantenint la simplicitat estructural i una bona cal·libració probabilística i versemblança.

Comparativa de Rendiment dels Models (10-fold CV)

Model	Acc. (%)	AUC	Brier	F1	Arcs	BIC	LogLik
NB_Full	**72.24**	**0.799**	0.225	**0.722**	24	−301,625	−300,782
ANB_Full	70.44	0.782	0.199	0.706	36	−246,721	−242,860
NB_MB	71.99	0.796	0.203	**0.722**	10	−126,734	−126,383
ANB_MB ⋆	71.75	0.794	**0.189**	0.717	**18**	−122,425	−120,825

⋆ *Model seleccionat. Tot i que NB_Full té lleugerament més Accuracy i AUC, l'ANB_MB és el model millor* **cal·librat** *(Brier Score mínim = 0.189) i amb el* **millor BIC** *entre els models reduïts.*

Tests Estadístics: Metodologia

Per comparar els models de manera rigorosa apliquem un procediment estadístic sobre les mètriques de cada fold (10 valors per model).

Pas 1 — Test de Shapiro-Wilk (normalitat)

- H_0: les mètriques del fold segueixen una distribució normal.
- **Resultat:** Tots els models passen la normalitat en les tres mètriques ($p > 0.05$).
- **Decisió:** S'aplica **Paired t-test** (unilateral).

Pas 2 — Paired t-test unilateral (H_1: Model 1 és millor)

- Per a **Accuracy** i **AUC**: H_1: Model 1 $>$ Model 2.
- Per a **Brier Score**: H_1: Model 1 $<$ Model 2 (error menor és millor).
- Es comparen tots els parells possibles (6 parells).

Tests Estadístics: Accuracy i AUC

Accuracy — Shapiro p: NB_Full=0.729, ANB_Full=0.748, NB_MB=0.896, ANB_MB=0.832 → *Paired t-test*

Model 1	Model 2	Mitjana 1	Mitjana 2	p-valor	Sig.
NB_Full	ANB_Full	0.7224	0.7044	< 0.001	***
NB_Full	NB_MB	0.7224	0.7199	0.0643	ns
NB_Full	ANB_MB	0.7224	0.7175	0.0662	ns
NB_MB	ANB_Full	0.7199	0.7044	< 0.001	***
ANB_MB	ANB_Full	0.7175	0.7044	< 0.001	***
NB_MB	ANB_MB	0.7199	0.7175	0.1691	ns

AUC — Shapiro p: NB_Full=0.794, ANB_Full=0.226, NB_MB=0.134, ANB_MB=0.392 → *Paired t-test*

Model 1	Model 2	Mitjana 1	Mitjana 2	p-valor	Sig.
NB_Full	ANB_Full	0.7993	0.7822	< 0.001	***
NB_Full	NB_MB	0.7993	0.7961	0.0101	*
NB_Full	ANB_MB	0.7993	0.7937	0.0008	***
NB_MB	ANB_Full	0.7961	0.7822	< 0.001	***
ANB_MB	ANB_Full	0.7937	0.7822	0.0006	***

Tests Estadístics: Brier Score ← Mètrica Decisiva

Brier Score — Shapiro p: NB_Full=0.525, ANB_Full=0.321, NB_MB=0.370, ANB_MB=0.408 → *Paired t-test*

Model millor	vs. Model	Mitjana millor	Mitjana altre	p-valor	Sig.
ANB_Full	NB_Full	0.1989	0.2251	< 0.001	***
NB_MB	NB_Full	0.2028	0.2251	< 0.001	***
ANB_MB	NB_Full	0.1886	0.2251	< 0.001	***
ANB_Full	NB_MB	0.1989	0.2028	0.0167	*
ANB_MB	**ANB_Full**	**0.1886**	**0.1989**	$\mathbf{< 0.001}$	***
ANB_MB	**NB_MB**	**0.1886**	**0.2028**	$\mathbf{< 0.001}$	***

Conclusió dels tests

L'**ANB_MB** té el Brier Score **significativament inferior** a tots els altres models ($p < 0.001$). En canvi, les diferències en Accuracy entre

Resultats i Conclusions

Selecció del Model Òptim: ANB_MB

- **Principi de Parsimònia:**
  - El Markov Blanket redueix les variables de 23 a **10**, amb **18 arcs** (vs. 24 del NB_Full).
  - S'eliminen variables irrellevants sense perdre capacitat predictiva significativa.
- **Cal·libració probabilística (Brier Score = 0.189):**
  - Significativament millor que tots els altres models ($p < 0.001$).
  - Les probabilitats del model són més fiables: evita la çonfiança excessiva"del NB.
- **BIC i estructura:**
  - Millor BIC entre els models reduïts ($-122{,}425$), penalitzant adequadament els 18 arcs.

Decisió Final

Es tria l'**ANB_MB** per la seva robustesa estadística, pel principi de parsimònia i per una cal·libració probabilística significativament superior.

Estudi de Casos

Metodologia de Predicció

El model final **ANB_MB** s'entrena sobre la totalitat de les dades. La inferència es fa exactament via Junction Tree del paquet `gRain`.

Per a cada escenari:

1. Codifiquem les variables observades al nivell de quantil (1–6) o binari.
2. Introduïm les variables del Markov Blanket com a **evidència** a la xarxa.
3. El model retorna $P(\texttt{blueWins} = 1 \mid \text{evidència})$.

Variables del Markov Blanket (model final, 18 arcs)

`blueDragons`, `blueTotalGold_disc`, `blueTotalJungleMinionsKilled_disc`, `redHeralds`, `redTowersDestroyed_disc`, `blueDeaths_disc`, `redWardsDestroyed_disc`, `redTotalExperience_disc`, `blueTotalExperience_disc`, `blueTotalMinionsKilled_disc`

Cas 1 i Cas 2: Domini i Equilibri

CAS 1: Equip Blau Dominant

- Gold blau: **molt alt** (n6)
- Experiència blava: **alta** (n5)
- Morts blaves: **molt baixes** (n1)
- Drac: **Sí** / Torre: **1**
- Exp. vermell: **baixa** (n2)

$$\mathbf{P}(\text{Victòria}) = \mathbf{93.0\%}$$

CAS 2: Bon farm sense objectius

- Gold blau: **per sobre** (n4)
- Morts blaves: **baixes** (n2) per a tots dos
- Sense objectius ni torres
- Exp. vermell: **normal** (n3)

$$\mathbf{P}(\text{Victòria}) = \mathbf{35.3\%}$$

Farm bo sense objectius no garanteix victòria: el model ho valora de manera moderada.

Cas 3 i Cas 4: Desavantatge i Avantatge Parcial

CAS 3: Blau en Desavantatge

- Gold blau: **baix** (n2)
- Exp. blava: **baixa** (n2)
- Morts blaves: **molt altes** (n6)
- Vermell té **Drac + Herald + Torre**

$$\mathbf{P}(\text{Victòria}) = \mathbf{8.0\%}$$

CAS 4: First Blood + Drac, Or Igualat

- Gold i Exp: **similars** (n4)
- Morts blaves: **n3** (neutres)
- Drac blau: **Sí**
- Sense torres destruïdes

$$\mathbf{P}(\text{Victòria}) = \mathbf{67.6\%}$$

El cas 4 confirma que el drac dóna un avantatge moderat però no definitiu quan l'or és igualat.

Resum de l'Estudi de Casos

#	Situació	Descripció breu	P(Victòria blava)
1	Dominant	Gold alt, exp alta, drac, torre, roig debilitat	**93.0%**
2	Farm passiu	Bon CS però sense objectius ni kills rellevants	**35.3%**
3	Desavantatge	Roig amb drac, herald i torre; blau amb poc or	**8.0%**
4	Avantatge parcial	Drac blau, or similar entre equips	**67.6%**

Interpretació global

El model ANB_MB retorna probabilitats ben cal·librades i coherents amb la teoria del joc: reflecteix l'efecte de les variables entre si, el valor dels objectius neutrals i la incertesa real en partides equilibrades.

Moltes gràcies!

Preguntes?